

AE2 — Atividade de Estudo 2

Desenho da Solução de Dados (Pré-implementação)

SP Verde & Ar — Monitoramento da Qualidade do Ar
e Arborização Urbana em São Paulo

Disciplina: Projeto Integrador com Dados

São Paulo, SP | 2026

1. DICIONÁRIO DE DADOS — Versão 1

O dicionário descreve todos os campos que compõem as três tabelas principais do projeto. Cada campo possui tipo esperado, origem, e regra de validação que será aplicada na etapa de qualidade.

1.1 Tabela: dim_distrito

Dimensão central do projeto. Contém os 96 distritos do município de São Paulo com seus atributos geográficos e socioeconômicos.

Campo	Tipo	Descrição	Origem	Regra de Validação
distrito_id	INTEGER	Identificador único do distrito (PK)	IBGE	NOT NULL; único; 1–96
nome_distrito	VARCHAR	Nome oficial do distrito	PMSP/GeoSampa	NOT NULL; sem caracteres especiais inválidos
subprefeitura	VARCHAR	Subprefeitura à qual pertence o distrito	PMSP	NOT NULL; domínio: lista oficial das 32 subprefeituras
area_km2	DECIMAL	Área total do distrito em km²	GeoSampa	NOT NULL; > 0; máx. esperado: 70 km²
populacao_2022	INTEGER	População residente (Censo IBGE 2022)	IBGE	NOT NULL; > 0; < 700.000
renda_media_sm	DECIMAL	Renda domiciliar média per capita (sal. mín.)	IBGE	NOT NULL; > 0; plausível: 0.5–20
idh_distrital	DECIMAL	IDH do distrito (proxy: IDH-M 2010 corrigido)	IBGE/Seade	0.400–0.999; NOT NULL
geom	GEOMETRY	Polígono do distrito (SRID 4326 / WGS84)	GeoSampa	NOT NULL; polígono válido; área coerente com area_km2 (±5%)

1.2 Tabela: fato_arborizacao

Fato com indicadores de cobertura vegetal e arborização pública por distrito e ano.

Campo	Tipo	Descrição	Origem	Regra de Validação
arb_id	INTEGER	PK da tabela de arborização	Gerado	NOT NULL; auto-incremental
distrito_id	INTEGER	FK para dim_distrito	GeoSampa	NOT NULL; deve existir em dim_distrito

ano_referencia	INTEGER	Ano da medição	GeoSampa	NOT NULL; entre 2018 e 2026
cobertura_vegetal_pct	DECIMAL	% da área do distrito coberta por vegetação	GeoSampa	NOT NULL; 0.0–100.0; maioria esperada: 5–60%
arvores_publicas_n	INTEGER	Número de árvores em vias públicas	GeoSampa	NOT NULL; >= 0; outlier se > 80.000
ica_score	DECIMAL	Índice de Cobertura Arbórea calculado (0–10)	Calculado	NOT NULL; 0–10; derivado de cobertura_vegetal_pct
fonte_shapefile	VARCHAR	Nome do arquivo shapefile de origem	GeoSampa	NOT NULL; deve constar no log de ingestão
data_carga	DATE	Data em que o registro foi carregado na base	Pipeline	NOT NULL; <= data atual

1.3 Tabela: fato_qualidade_ar

Fato com medições de poluentes por estação CETESB, agregadas mensalmente por distrito via interpolação espacial.

Campo	Tipo	Descrição	Origem	Regra de Validação
ar_id	INTEGER	PK da tabela de qualidade do ar	Gerado	NOT NULL; auto-incremental
distrito_id	INTEGER	FK para dim_distrito	CETESB	NOT NULL; deve existir em dim_distrito
estacao_cetesb	VARCHAR	Nome da estação CETESB mais próxima	CETESB	NOT NULL; domínio: lista oficial de 38 estações SP
ano_referencia	INTEGER	Ano da medição	CETESB	NOT NULL; entre 2018 e 2026
mes_referencia	INTEGER	Mês da medição (1–12)	CETESB	NOT NULL; 1–12
pm25_media_ug_m3	DECIMAL	Concentração média mensal de PM2,5 (µg/m³)	CETESB	NOT NULL; 0–500; limite OMS: 15; limite CONAMA: 25
pm10_media_ug_m3	DECIMAL	Concentração média mensal de PM10 (µg/m³)	CETESB	NOT NULL; 0–600; limite OMS: 45
o3_media_ug_m3	DECIMAL	Concentração média mensal de Ozônio O3 (µg/m³)	CETESB	NOT NULL; 0–400

iep_score	DECIMAL	Índice de Exposição à Poluição calculado (0–10)	Calculado	NOT NULL; 0–10; derivado de PM2,5 ponderado por pop.
metodo_espacial	VARCHAR	Método de interpolação usado (ex.: IDW, Kriging)	Pipeline	NOT NULL; domínio: ['IDW','Kriging','Voronoi','Direto']
data_carga	DATE	Data de carga na base	Pipeline	NOT NULL; <= data atual

1.4 Tabela: fato_ivsa (tabela analítica calculada)

Tabela resultante da integração das outras tabelas. Contém o IVSA final por distrito e ano.

Campo	Tipo	Descrição	Origem	Regra de Validação
ivsa_id	INTEGER	PK	Gerado	NOT NULL; auto-incremental
distrito_id	INTEGER	FK para dim_distrito	Calculado	NOT NULL; deve existir em dim_distrito
ano_referencia	INTEGER	Ano de referência do IVSA	Calculado	NOT NULL; 2018–2026
ica_score	DECIMAL	Pontuação ICA do distrito no ano (0–10)	fato_arb.	NOT NULL; 0–10
iep_score	DECIMAL	Pontuação IEP do distrito no ano (0–10)	fato_ar	NOT NULL; 0–10
idh_normalizado	DECIMAL	IDH distrital normalizado (0–10, invertido)	dim_dist.	NOT NULL; 0–10
ivsa_score	DECIMAL	Score final IVSA = (10-ICA)+IEP+(10-IDH*10)	Calculado	NOT NULL; 0–30; ranqueado
ranking_ivsa	INTEGER	Posição no ranking (1 = mais vulnerável)	Calculado	NOT NULL; 1–96

2. MODELO LÓGICO — Versão 1

O modelo adota arquitetura Star Schema (esquema estrela): uma tabela dimensão central (dim_distrito) e três tabelas fato/analítica. O diagrama completo está disponível no arquivo AE2_Diagrama_Modelo_Logico.png entregue junto a este documento.

2.1 Descrição tabular dos relacionamentos

Tabela	Tipo	PK	FK	Relacionamento
dim_distrito	Dimensão	distrito_id	—	Tabela central. Referenciada por todas as tabelas fato.
fato_arborizacao	Fato	arb_id	distrito_id	N:1 com dim_distrito. Um distrito tem N registros (um por ano).
fato_qualidade_ar	Fato	ar_id	distrito_id	N:1 com dim_distrito. Um distrito tem N registros (ano+mês).
fato_ivsa	Analítica	ivsa_id	distrito_id	N:1 com dim_distrito. Gerada via JOIN das duas tabelas fato.

2.2 Diagrama textual — estrutura das tabelas

3. PLANO DE QUALIDADE DE DADOS

As 8 checagens abaixo serão implementadas como funções Python executadas logo após a ingestão de cada dataset. Cada checagem gera um relatório de qualidade (JSON) com status PASS/FAIL, contagem de erros e exemplos dos registros problemáticos.

#	Checagem	Tabela(s)	Regra	Ação em caso de FAIL
Q 1	Duplicidade de PK	Todas	COUNT(DISTINCT PK) = COUNT(*) em cada tabela	Remover duplicatas; registrar no log; alertar responsável
Q 2	Nulos em obrigatórios	Todas	Campos NOT NULL não podem conter NULL ou string vazia	Rejeitar linha; registrar no relatório de qualidade
Q 3	Domínio de valores	dim_distrito fato_ar	subprefeitura ∈ lista oficial; estacao_cetesb ∈ lista CETESB	Rejeitar linha; checar se houve nova estação/subprefeitura
Q 4	Faixas plausíveis	fato_qualidade_ar	PM2,5: 0–500 µg/m³; PM10: 0–600; O3: 0–400; IEP: 0–10	Marcar como suspeito; não usar no cálculo do IVSA
Q 5	Faixas plausíveis	fato_arborizacao	cobertura_vegetal_pct: 0–100%; ica_score: 0–10	Marcar como suspeito; investigar shapefile de origem
Q 6	Integridade referencial	fato_* → dim_dist.	Todo distrito_id em fato_* deve existir em dim_distrito	Rejeitar linha órfã; verificar se distrito foi criado/extinto
Q 7	Consistência temporal	fato_qualidade_ar	Não pode haver gap > 3 meses consecutivos por estação/distrito	Interpolarmar ou marcar mês como sem dado; documentar lacuna
Q 8	Coerência geométrica	dim_distrito	area_km2 deve ser coerente com área calculada do geom (±5%); polígono válido sem auto-interseção	Recalcular area_km2 a partir do geom; logar diferença

3.1 Critério de aceitação geral

- Taxa de registros válidos (sem FAIL em Q1–Q8) ≥ 95% em cada tabela para prosseguir para a análise.
- Qualquer FAIL nos campos ica_score, iep_score ou ivsa_score bloqueia o cálculo do IVSA até correção.
- Relatório de qualidade gerado automaticamente a cada execução do pipeline e salvo em /data/quality_reports/.
- Resultados da última execução documentados no README do repositório.

4. PLANO DE ANÁLISE (EDA) E PRODUTO FINAL

4.1 Análise Exploratória de Dados (EDA)

A EDA será conduzida em notebooks Jupyter organizados em três etapas:

Etapa	Análise	Gráficos / Tabelas	Pergunta Respondida
EDA 1	Distribuição univariada	Histogramas de PM2,5, ICA, IDH; boxplots por subprefeitura	Qual a distribuição dos indicadores? Há outliers?
EDA 2	Correlação ICA × IDH	Scatter plot ICA vs IDH; heatmap de correlação de Pearson	PA2: IDH alto → mais arborização?
EDA 3	Sazonalidade do PM2,5	Linha temporal PM2,5 mensal (2020–2025); boxplot seco vs chuvoso	PA3: Seco = poluição maior?
EDA 4	Análise espacial	Mapas coropléticos: ICA, IEP, IVSA por distrito (folium/geopandas)	PA1: Onde se concentra a vulnerabilidade?
EDA 5	Exposição × Renda	Scatter PM2,5 vs renda_media_sm; bar chart por quartil de renda	PA4: Pobres mais expostos à poluição?
EDA 6	Ranking IVSA	Bar chart top 10 + bottom 10 distritos; tabela comparativa	Quais são os 10 mais vulneráveis?

4.2 Insights esperados

- Distritos periféricos (ex.: Parelheiros, Marsilac, Anhanguera) devem apresentar menor ICA e maior IEP simultaneamente.
- Distritos com IDH mais baixo devem ter menor cobertura arbórea (hipótese de desigualdade ambiental).
- PM2,5 no período seco (maio–outubro) deve superar o limite OMS de 15 µg/m³ em ao menos 40% dos distritos.
- A população de baixa renda está desproporcionalmente exposta a concentrações de PM2,5 acima do limite OMS.
- O IVSA deve revelar um padrão espacial claro: periferias sul e leste como bolsões de vulnerabilidade.

4.3 Esboço do Dashboard — Wireframe (páginas e visuais)

O dashboard será desenvolvido em Python/Plotly Dash e terá 4 páginas principais. O wireframe visual completo está no arquivo AE2_Wireframe_Dashboard.png. A seguir, a descrição estrutural de cada página:

Página	Título	Visuais / KPIs	Filtros
--------	--------	----------------	---------

Pág. 1 — Home	Visão Geral	KPI cards: média PM2,5 SP; % pop. acima OMS; distritos críticos. Mapa coroplético IVSA geral.	Ano de referência
Pág. 2 — Ar	Qualidade do Ar	Mapa PM2,5 por distrito; linha temporal PM2,5 mensal; ranking top 10 piores distritos; boxplot seco vs. chuvoso.	Ano; poluente (PM2,5, PM10, O3); estação CETESB
Pág. 3 — Verde	Arborização Urbana	Mapa ICA por distrito; scatter ICA vs IDH; bar chart % cobertura por subprefeitura; top 10 melhor/pior ICA.	Ano; subprefeitura
Pág. 4 — IVSA	Vulnerabilidade	Mapa IVSA final; ranking completo 96 distritos; tabela comparativa ICA+IEP+IDH+IVSA; botão download CSV.	Ano; subprefeitura; quartil de renda

Nota: o wireframe visual está no arquivo AE2_Wireframe_Dashboard.png, disponível em /docs/escopo-1/AE2/ no repositório GitHub.

5. ATUALIZAÇÃO DO GITHUB

5.1 Estrutura de pastas definida

Estrutura atualizada do repositório após a AE2:

```
projeto-sp-verde-ar/
├── README.md                                ← atualizado com link da AE2
├── docs/
│   ├── escopo-1/
│   │   ├── AE1/
│   │   │   ├── AE1_Projeto_Extensionista.docx
│   │   │   ├── AE2/                                ← NOVO
│   │   │   │   ├── AE2_Desenho_Solucao.pdf
│   │   │   │   ├── AE2_Diagrama_Modelo_Logico.png
│   │   │   │   └── AE2_Wireframe_Dashboard.png
│   └── data/
│       ├── raw/
│       ├── processed/
│       ├── outputs/
│       ├── quality_reports/                    ← NOVO
│       ├── notebooks/
│       │   ├── 01_eda_univariada.ipynb
│       │   ├── 02_analise_espacial.ipynb
│       │   ├── 03_ivsa_calculo.ipynb
│       │   ├── 04_qualidade_dados.ipynb        ← NOVO
│       ├── src/
│       │   ├── coleta.py
│       │   ├── limpeza.py
│       │   ├── qualidade.py                    ← NOVO
│       │   └── visualizacao.py
│       ├── dashboard/app.py
│       └── .gitignore
```

5.2 Issues/tarefas para execução futura (mín. 6)

Issues a serem criadas no GitHub com as respectivas labels:

#	Título da Issue	Label	Descrição resumida
# 1	Coletar shapefiles de arborização (GeoSampa)	data/coleta	Baixar e versionar os shapefiles dos 96 distritos. Registrar data de captura no README.
# 2	Baixar séries históricas CETESB 2020–2025	data/coleta	Acessar cetesb.sp.gov.br/ar, baixar planilhas anuais de PM2,5/PM10/O3 e salvar em /data/raw/.
# 3	Implementar pipeline de limpeza e integração	data/pipeline	Criar src/limpeza.py com funções de padronização, join das tabelas e geração do dataset final.

# 4	Implementar as 8 checagens de qualidade de dados	qualidade	Criar src/qualidade.py com as checagens Q1–Q8. Gerar relatório JSON em /data/quality_reports/.
# 5	Calcular IVSA para todos os 96 distritos	análise	Criar notebook 03_ivsa_calculo.ipynb com a fórmula e o ranking final dos distritos.
# 6	Desenvolver análise espacial e mapas coropléticos	análise	Criar notebook 02_analise_espacial.ipynb com mapas folium/geopandas do ICA, IEP e IVSA.
# 7	Construir dashboard Plotly Dash (4 páginas)	produto	Implementar dashboard/app.py com as 4 páginas definidas no wireframe da AE2.
# 8	Atualizar README com resultados da AE2 e AE3	documentação	Incluir prints do dashboard, link do dataset publicado e referências atualizadas.